

Sisteme Inteligente

Barem de Evaluare - Proiect

An universitar 2025–2026

Deliverable	Titlu	Termen	Pondere	Nota max.
D1 + D2	Know Your Data! + Tabular Data Project	Săptămâna 6	(20% pentru D1, 30% pentru D2)	10p
D3	Deep Learning Project	Săptămâna 13	50%	10p

Notă finală: medie ponderată - $D1 \times 20\% + D2 \times 30\%$, $D3 \times 50\%$. Fiecare grup de deliverable se notează independent.

Alte detalii deadline-uri: D1 și D2 se predau împreună în Săptămâna 6 ca două notebook-uri separate (sau un singur notebook cu secțiuni clar delimitate). Analizarea overfit/underfit este tratată în D3 (Săptămâna 13).

Note: Datasetul pentru D1 și D2 trebuie să fie unul tabular, fără imagini sau alte tipuri de date decât cele în format tabular (.csv .tsv .xlsx etc.) P.S. fără poze sau altceva :P

Framework-uri: Pandas, Numpy, Scikit-Learn, PyTorch (la alegere în funcție de use-case-ul ales) —

Predare: notebook(uri) .ipynb sau scripturi .py cu toate celulele rulate (raport PDF doar pentru D3)

D1 + D2 — Know Your Data! & Tabular Data Project

Săpt. 6

Deadline comun Săptămâna 6. Se predau **două notebook-uri separate** (sau un singur .ipynb cu o celulă Markdown de separare clară: `### == D1: Know Your Data ==` respectiv `### == D2: Tabular Data Project ==`). Dataset-ul este ales liber și trebuie să fie potrivit pentru un task de ML supervizat.

D1 — Know Your Data!

1.1.1 Obiectiv

Familiarizarea cu datele. **Nu se cere niciun model antrenat** — accentul cade exclusiv pe înțelegerea datasetului.

1.1.2 Conținutul așteptat

1. Descrierea datasetului

- Sursa datelor (link, platformă: Kaggle, UCI, Hugging Face etc.)
- Dimensiune: număr rânduri, număr coloane
- Tipul taskului: clasificare binară / multclasă / regresie
- Variabila țintă (*target*) - ce vrei să prezici?
- Scurtă descriere a coloanelor relevante

2. Exploratory Data Analysis (EDA)

- **Obligatoriu** Statistici descriptive (`df.describe()`) + distribuția claselor targetului
- **Obligatoriu** Analiza valorilor lipsă: câte, pe ce coloane, strategie propusă (argumentat)
- **Obligatoriu** Distribuții + outlieri — minim 3–5 vizualizări (histograme, boxplots)
- **Obligatoriu** Heatmap de corelații (Pearson/Spearman) + comentariu scris despre corelațiile relevante
- *Recomandat* Scatter plots, pairplot, vizualizări specifice tipului de date

3. Concluzii din EDA

- Minim un paragraf narativ (text Markdown, nu doar cod) cu observații despre date
- Probleme identificate: dezechilibru de clase, missing values, outlieri
- Preprocessing anticipat pentru D2

1.1.3 Barem D1 - 10 puncte

Criteriu	Punctaj	Observații
Descrierea completă a datasetului	2.0 p	Sursă, dimensiune, task, target
Statistici descriptive + distribuția targetului	1.0 p	Rulat și comentat
Analiza valorilor lipsă + strategie propusă	2.0 p	Nu doar cod, și text
Distribuții + outlieri (minim 3 viz.)	2.0 p	Vizualizări relevante
Heatmap corelații + comentariu	1.5 p	Comentariu obligatoriu
Concluzii scrise (paragraf narativ)	1.5 p	Nu se acceptă doar cod
TOTAL D1	10.0 p	

D2 — Tabular Data Project

1.2.1 Obiectiv

Soluție completă de ML pe date tabulare: preprocessing, antrenare și comparare de modele, metrice, concluzii argumentate. **Nota:** Analiza overfit/underfit (curbe de learning etc.) va fi adresată în D3 - nu este obligatorie în D2.

1.2.2 Conținutul așteptat

1. Preprocessing & Feature Engineering

- Tratarea valorilor lipsă (imputare sau eliminare - justificată)
- Encoding variabile categorice (`LabelEncoder`, `OneHotEncoder` - ales motivat)
- Normalizare/standardizare (`StandardScaler`, `MinMaxScaler`) - când și de ce
- Tratarea dezechilibrului de clase dacă există (oversampling, `class_weight` etc.)
- Split train/test cu seed fixat pentru reproductibilitate

2. Experimente + Model Final

- **Minim 3 modele** antrenate și comparate (ex.: Logistic Regression, Decision Tree, Random Forest, Naive Bayes, KNN, SVM)
- Pentru fiecare model: argument scris pentru alegere (de ce acest model pe aceste date?)
- Metrice raportate: accuracy, precision, recall, confusion matrix (clasificare) sau MSE/MAE/R² (regresie)
- Nu este punctată acuratețea propriu zisă a modelelor, dar pipeline-ul trebuie să fie unul corect, care în teorie ar putea să producă rezultate bune.

3. Concluzii

- Care model performează cel mai bine și de ce?
- Minim un paragraf de concluzii argumentate
- Ce ați face diferit cu mai mult timp/resurse?

1.2.3 Barem D2 - 10 puncte

Criteriu	Punctaj	Observații
Preprocessing complet și justificat	3.0 p	Fiecare pas argumentat
Minim 3 modele cu argumente pentru alegere	3.0 p	Nu doar rulat, și explicat
Metrici corecte + confusion matrix / echivalent	2.0 p	Adecvate tipului de task
Concluzii argumentate	2.0 p	Analiză prin comparație obligatorie
TOTAL D2	10.0 p	

Notă importantă: Hyperparameter tuning și analiza overfit/underfit *nu* sunt cerute în D2; vor fi evaluate în D3.

Penalizări frecvente D1+D2

- Notebook fără celule rulate (output gol) → **-2p**
- Lipsă complet concluzii scrise în D1 → **-0.75p**
- Un singur model antrenat în D2 → max. 2.5p din D2
- Metrici fără nicio interpretare → **-0.5p**
- Preprocessing absent (date brute direct în model) → **-1.5p**
- Copiat de pe Kaggle fără adaptare sau comentariu propriu → **0p**

Bonus D1+D2 (max. +1p total)

- **+0.5p** Pipeline sklearn complet (**Pipeline** + **ColumnTransformer** + **GridSearchCV**)
- **+0.5p** Experimentare cu model neabordat la laborator (XGBoost, LightGBM, SVM cu kernel neliniar)
- **+0.5p** Vizualizări avansate EDA (SHAP values, feature importance cu barplot îngrijit, distribuții condiționate)